뉴스의 긍정/부정 성향과 주가 등락률의 상관성 분석 및 제언

이선역
휴먼지능정보공학전공
202310861

Ⅰ. 분석 배경

주식 시장은 주식과 관련된 많은 뉴스를 생산한다. 많은 투자자는 뉴스를 통해 많은 정보를 얻고 투자 기업의 실태를 파악한다. 따라서 뉴스는 주식 시장에 영향을 미치는 핵심 요인 중 하나이다.

본 분석은 2024년 1월 1일부터 2025년 11월 15일까지 대한민국 주식 시장 시가총액 상위 3개 기업인 삼성전자, SK하이닉스, LG에너지솔루션의 주식 등락률과 같은 기간의 각 기업에 대한 뉴스의 긍정/부정 성향과의 상관관계를 파악하고자 한다. 이를 통해 뉴스의 긍정/부정 성향이 주가 등락률의 어떤 관련이 있는지 검토하고, 향후 뉴스에 따른 주식 거래 방향성에 대한 정보를 제공하는 것을 목적으로 한다.

Ⅱ. 분석 준비

2.1 데이터 목록

본 분석에서는 KRX 정보 데이터시스템을 통해 세 가지 데이터를, 네이버 증권 뉴스에서 크롤링을 통해 세 가지 데이터를 사용했다. 추가적으로 사용한 데이터의 명칭을 회사 그룹 이름으로 통일하여 가독성을 높였다.

samsung_stock.csv: 설정한 기간에 따른 삼성전자 주식 데이터, 이하 '삼성 주식 데이터'라 한다.

lg_stock.csv: 설정한 기간에 따른 LG에너지솔루션 주식 데이터, 이하 'LG 주식 데이터'라 한다.

sk_stock.csv: 설정한 기간에 따른 SK하이닉스 주식 데이터, 이하 'SK 주식 데이터'라 한다.

naver_finance_titles_삼성전자.csv: 설정한 기간에 따른 삼성전자 뉴스 제목 데이터, 이하 '삼성 뉴스 데이터'라 한다.

naver_finance_titles_LG.csv: 설정한 기간에 따른 LG에너지솔루션 뉴스 제목 데이터, 이하 'LG 뉴스 데이터'라 한다.

naver_finance_titles_Sk.csv: 설정한 기간에 따른 SK하이닉스 뉴스 제목 데이터, 이하 'SK 뉴스 데이터'라 한다.

2.2 데이터 전처리

먼저 '삼성 주식 데이터', 'LG 주식 데이터', 'SK 주식 데이터'에서 제공하는 일자별 종가, 대비, 등락률, 시가, 고가, 저가, 거래량, 거래대금, 시가총액, 상장주식수 중에서 일자별 등락률, 거래량만 가지고 와서 processing_samsung_stock.csv, processing_lg_stock.csv, processing_sk_stock.csv 파일을 만들었다.

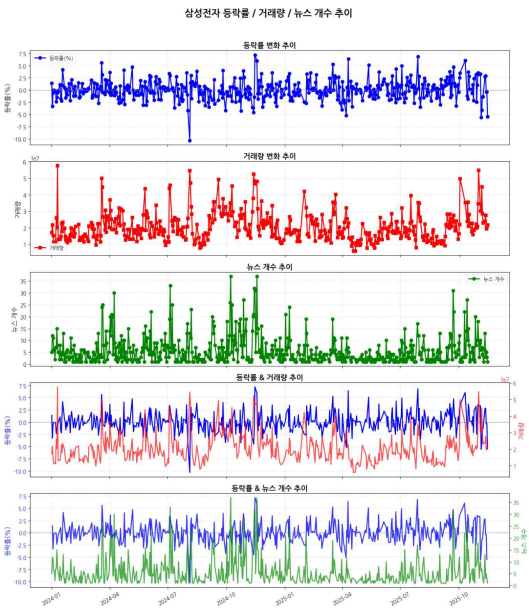
다음으로 삼성 뉴스 데이터', 'LG 뉴스 데이터', 'SK 뉴스 데이터'에서 제공하는 모든 뉴스 제목을 키워드 단위로 분류 후 키워드별 반복 등장 횟수를 계산하고, 기업별로 의미 없는 키워드는 제거하고 키워드의 개수를 오차범위 10개 이내로 맞춰주기 위하여 키워드별 최소 반복 횟수를 지

정한 후 samsung_word.csv, lg_word.csv, sk_word.csv 파일을 만들었다.

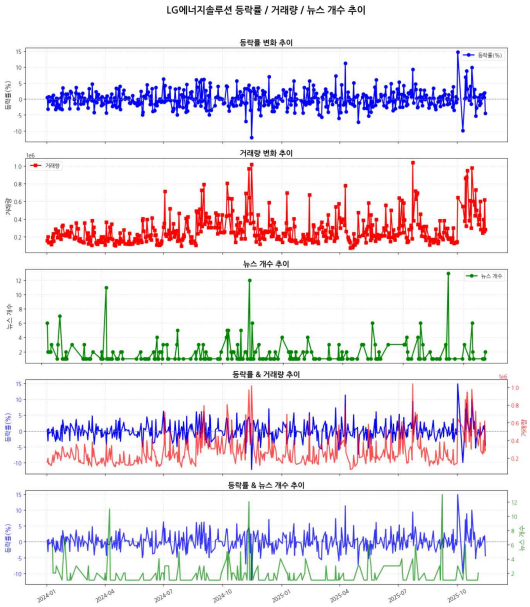
마지막으로 위에 만든 samsung_word.csv, lg_word.csv, sk_word.csv 파일에 담겨있는 키워드를 분류해 긍/부정 점수를 지정한 후 그 정보를 추가했다. 기업 주가 등락률에 긍정적인 영향을 줄 것으로 기대되는 키워드라고 판단되면 1.0의 점수를 부여했으며, 중립은 0.5, 부정적인 영향을 줄 것이라고 기대되는 키워드는 0점의 점수를 부여했다. 점수를 부여하는 과정은 분야에 대한 지식이 있는 사람이 진행했다.

2.3 데이터 시각화

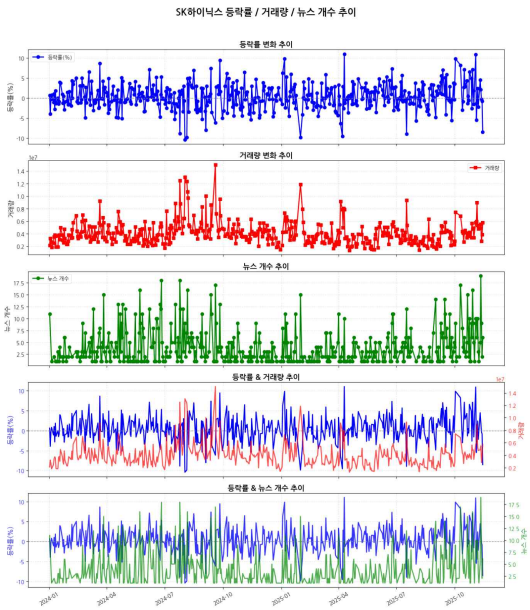
2.3.1 기업 주식 데이터, 기업 뉴스 데이터를 활용한 주식 등락률, 거래량, 뉴스 개수 추이 시각화



그래프 1 삼성전자 등락률/거래량/뉴스 개수 추이



그래프 2 LG에너지솔루션 등락률/거래량/뉴스 개수 추이



그래프 3 SK하이닉스 등락률/거래량/뉴스 개수 추이

육안으로는 3개 기업에 대한 그래프의 속성 간의 유의한 관계를 찾기 어려웠다. 따라서 가설을 설정한 후 가설 검정을 진행하였다.

2.3.2 뉴스 키워드 데이터 시각화



그림 1 삼성전자 뉴스 키워드 워드 클라우드



그림 2 LG에너지솔루션 뉴스 키워드 워드 클라우드



그림 3 SK하이닉스 뉴스 키워드 워드 클라우드

워드 클라우드를 통해 기업별 어떤 단어가 가장 높은 빈도를 보이고 있는지 시각화하였다.

2.4 추가적인 전처리

앞서 긍/부정 점수를 부여한 키워드를 활용해 기업별 뉴스 제목의 어떤 키워드가 들어있는지 확인 후 긍/부정 점수를 부여한다.

이 과정을 진행한다면 뉴스 대부분에 점수가 부여되나, 하나의 키워드도 없는 경우, 중립 단어만 있으면 해당 뉴스의 긍/부정 점수가 0.5로 나오게 된다. 이러한 경우에도 제거하지 않고 진행했다.

Ⅲ. 분석 방법 및 결과

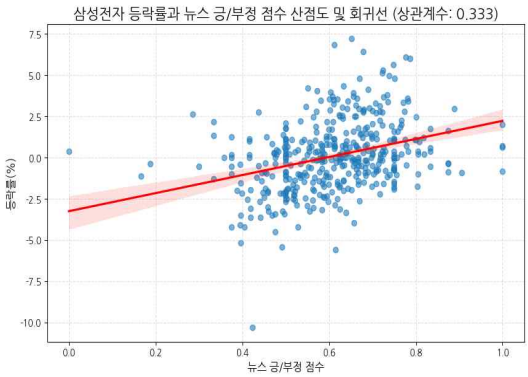
3.1 피어슨 상관분석

본 분석에서 사용되는 데이터는 연속형 수치 데이터이면서 증감률로 표현되어 의미있는 비율 관계가 존재한다. 또한 특정 기업의 긍정적인 뉴스가 증가하면 그 기업의 주가 등락률이 양의 값으로 증가할 것이라는 선형적 관계를 가정하고 있으므로 '피어슨(Pearson)' 상관분석으로 진행했다.

먼저 앞서 긍/부정 점수가 부여된 뉴스들을 일자별로 묶는다. 이후 일자별 주식 등락률과의 상관분석을 진행한다.

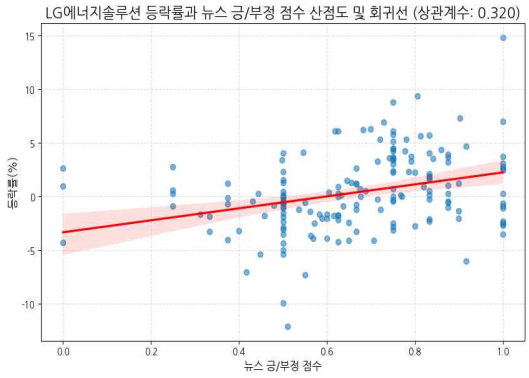
일자별 주식 증감량을 일자별 뉴스 긍/부정 점수와 함께 pearsonr() 함수에 변수로 넣어 상관계수와 p-value를 구한다. 이때 p-value 가 0.05 보다 작으면 유의하고 그렇지 않으면 유의하지 않다.

상관분석 결과는 다음과 같다.

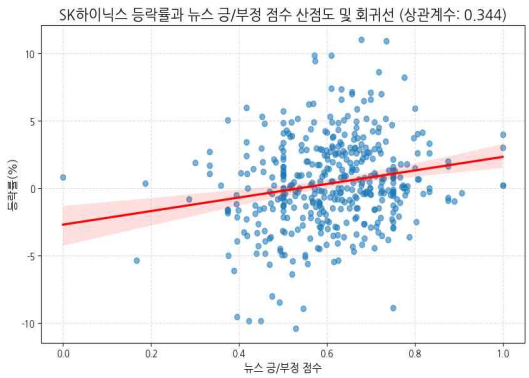


삼성전자 피어슨 상관 검정
상관계수 (r): 0.333
p-value: 0.00000000000220191612

LG에너지솔루션 피어슨 상관 검정
상관계수 (r): 0.320
p-value: 0.00001868400507851794



SK하이닉스 피어슨 상관 검정
상관계수 (r): 0.196
p-value: 0.00005158190247690753



3개의 기업이 모두 양의 상관관계를 보이고 있고, 상관관계 검정 결과 모두 유의함을 알 수 있다.

3.2 정상성 검정

추가로 분석의 신뢰도를 확보하고 허위 상관관계를 방지하기 위해, 각 기업의 주가 등락률 데이터에 대해 ADF(Augmented Dickey-Fuller) 검정을 진행하였다.

삼성전자 등락률 ADF Test
ADF Statistic: -19.662470
p-value: 0.0000
Critical Values:
1%: -3.4448
5%: -2.8679
10%: -2.5702

LG에너지솔루션 등락률 ADF Test
ADF Statistic: -24.884968
p-value: 0.0000
Critical Values:
1%: -3.4448
5%: -2.8679
10%: -2.5702

SK하이닉스 등락률 ADF Test
ADF Statistic: -21.385027
p-value: 0.0000
Critical Values:
1%: -3.4448
5%: -2.8679
10%: -2.5702

조사한 기업들인 삼성전자($t=-19.66$, $p<0.001$), LG에너지솔루션($t=-24.88$, $p<0.001$), SK하이닉스($t=-21.38$, $p<0.001$) 모두 유의수준 1% 하에서 귀무가설이 기각되었다. 이는 수집된 주가 등락률 데이터가 정상 시계열임을 알 수 있다.

따라서 별도의 추가적인 차분 과정 없이, 해당 데이터를 활용하여 상관분석을 수행하는 데 통계적 오류가 없음을 확인했다.

Ⅳ. 결과 해석 및 한계

4.1 결과 해석

주식의 등락률과 해당 주식의 기업에 관한 뉴스의 긍/부정 경향성은 양의 상관관계가 있음을 알 수 있다. 그러나 유심히 판단해야 할 것은 상관계수가 우리의 직관과 다르게 0.19~0.33 수준으로 낮게 나왔다는 점이다. 이는 주식 등락률은 다양한 원인을 가지고 있기 때문이라고 생각한다.

4.2 한계

첫째, 매우 짧은 기간, 매우 적은 기업들만을 조사한 것이기 때문에 전체적인 경향성만 알 수 있지, 구체적인 수치를 신뢰할 수 없다.

둘째, 뉴스의 긍/부정 점수를 평가하는 키워드는 사람이 분류했기 때문에 정성적인 분류가 이루어졌을 가능성이 있다.

셋째, 키워드 간의 연관성으로 뉴스의 긍/부정 점수가 결정되는 때도 있지만, 본 연구에서는 없다고 가정했다.

넷째, 본 연구는 상관관계 분석에 기반한 것으로 뉴스의 긍/부정 경향성이 주가 등락률에 직접적인 영향을 주는 인과관계임을 의미하지 않는다. 따라서 본 분석은 통계적 연관성을 확인한 것으로 해석해야 하며 구체적인 서비스를 구현할 때는 다각적인 인과관계 검증이 필요하다.

Ⅴ. 정책적 제언

분석 결과 및 해석을 바탕으로 다음 두 개의 정책적 제언을 제시한다.

첫째, 특정 기업에 관한 긍정적인 뉴스가 많아질 것으로 예상될 때 해당 기업의 주식이 상승할 가능성이 있다는 점을 고려하여 투자하는 것이 효과적일 것이다.

둘째, 특정 기업에 관한 부정적인 뉴스가 많아질 것으로 예상될 때 해당 기업의 주식이 하락할 가능성이 있다는 점을 고려하여 투자하는 것이 효과적일 것이다.